



MÓDULO M7

AMAZON EC2 AVANZADO — ASG, ELB Y ELASTIC IP (DOMINIO 3)



MÓDULO M7

Sesión 7.1 — Elastic IP — EIP (dirección IP elástica)



¿QUÉ ES UNA IP ELÁSTICA (EIP)?

- Actúa como un **punto de enlace fijo** para tus recursos en la nube.
- A diferencia de las IPs estándar, su dirección **nunca cambia** ni se pierde **aunque detengas o reinicies la instancia.**
- Tarifa estándar: **\$0.005 USD** por hora, se factura por **todas las IPs públicas**, sin importar si están asociadas a una instancia en ejecución o si están ociosas (Idle).
- **Idle (ocioso) EIP** ⇒ **billing importante** (*no dejes EIPs huérfanas*).



IP PÚBLICA FIJA VS DINÁMICA



- **Public IP (IP pública):**

- IPv4 pública **asignada automáticamente** a la instancia. (**IP dinámica**)
- Puede cambiar al hacer **stop/start** de EC2.
- Útil para **pruebas** o cargas temporales.

- **Elastic IP (EIP) / «IP elástica»:**

- IPv4 pública **estática** asociada a tu cuenta AWS.
- Mantiene la **misma IP** aunque hagas **stop/start** a la instancia.
- Ideal cuando necesitas un punto de entrada estable.

Elastic IP / IP elástica = punto de entrada estable conocido desde fuera IPv4.

CHECK YOURSELF?



Una instancia **EC2** se detiene (stop) y reinicia (start). ¿Su **IP pública dinámica** cambia?



Una **Elastic IP** no está asociada a ninguna instancia. ¿Se cobra?

ANSWERS



✓ Sí. La IP pública dinámica puede cambiar en cada ciclo stop/start. Para tener IP fija se usa **Elastic IP (EIP)**.



✓ Sí. Una **EIP** inactiva (idle / sin asociar) genera costo. Solo es gratuita mientras está **asociada a una instancia en ejecución** (running instance).





MÓDULO M7

Sesión 7.2 — Escalabilidad, Elasticidad y Agilidad



ESCALABILIDAD ≠ ELASTICIDAD ≠ AGILIDAD



- **Escalabilidad (Scalability):** Capacidad de manejar mayor carga aumentando recursos. Puede ser **vertical** (instancia más grande) u **horizontal** (más instancias). **No implica automatismo.**
- **Elasticidad (Elasticity):** Capacidad de **escalar automáticamente** según la demanda real, **subiendo Y bajando** sin intervención manual. Pagas solo lo que usas.
- **Agilidad (Agility):** Capacidad de obtener **nuevos recursos en minutos** (no semanas), permitiendo experimentar y desplegar rápido. **NO se trata de tamaño**, se trata de **velocidad de aprovisionamiento.**



ESCALABILIDAD Y ALTA DISPONIBILIDAD



- La escalabilidad significa que una aplicación/sistema puede **manejar mayores cargas adaptándose**.
- Hay dos tipos de escalabilidad:
 - **Escalabilidad vertical**
 - **Escalabilidad horizontal** (= elasticidad)
- La escalabilidad está vinculada pero es **diferente a la alta disponibilidad**



ESCALABILIDAD VERTICAL VS HORIZONTAL



VERTICAL



- Aumentar CPU, RAM o disco.
- Más potencia en un solo servidor.
- Límite físico claro.
- Escalar esa aplicación verticalmente significa ejecutarla en una instancia t3.large.

HORIZONTAL



- Multiplicar instancias idénticas.
- Alta disponibilidad
- Base del cloud moderno.
- Es fácil escalar horizontalmente gracias a las ofertas en el Cloud como Amazon EC2.

CHECK YOURSELF?

?

Una startup quiere lanzar una landing de prueba para validar una idea **este viernes** sin comprar servidores. ¿Qué beneficio del cloud aplica?

?

Un e-commerce necesita que su web **soporte automáticamente** un pico de tráfico el Black Friday y vuelva a un tamaño mínimo el lunes. ¿Qué concepto describe esto?

?

Una empresa migra una aplicación on-premises a AWS y quiere poder pasar de una instancia **t3.medium** a una **m5.large** cuando crezca el negocio el próximo trimestre. ¿Qué concepto aplica?

ANSWERS



✓ **Agilidad.** Aprovisiona los recursos en minutos sin necesidad de planificación de capacidad ni inversiones largas. **No es elasticidad** porque la pregunta no menciona escalar arriba/abajo según demanda; es velocidad de obtener recursos.



✓ **Elasticidad.** El sistema escala arriba y abajo **automáticamente** sin intervención humana, ajustándose a la demanda real. La elasticidad implica el ciclo completo: scale-out cuando sube + scale-in cuando baja. La escalabilidad solo cubre la capacidad de crecer.



✓ **Escalabilidad (vertical).** Es la capacidad de manejar más carga aumentando el tamaño del recurso. **No es elasticidad** porque no es automático según demanda — es una decisión planificada manualmente.






MÓDULO M7

Sesión 7.3: Auto Scaling Groups — ASG



¿QUÉ ES UN AUTO SCALING GROUP?

- En la vida real, la carga de tus sitios web y aplicaciones puede cambiar.
- En el Cloud, puedes **crear y deshacerte** de **servidores** muy **rápidamente**.
- El objetivo de un Auto Scaling Group (ASG) es:
 - Escalar para fuera (añadir instancias de EC2) para adaptarse a un aumento de la carga.
 - Escalar para dentro (eliminar instancias EC2) para que coincida con una disminución de la carga.
- **Asegurar** que tenemos un **número mínimo y máximo** de **máquinas** en **funcionamiento**.
- **Registrar automáticamente** nuevas instancias en un **Load Balancer**.
- **Reemplazar** las **instancias** en mal estado.



AUTO SCALING



- **Amazon EC2 Auto Scaling:** **Ajusta** automáticamente la **cantidad de servidores virtuales** (instancias) para mantener el **rendimiento y reducir costos**, agregando o eliminando capacidad según la **demanda real del tráfico**.
 - **Añade instancias:** Cuando aumenta el tráfico.
 - **Elimina instancias:** Cuando baja el tráfico.
 - **Mantiene disponibilidad:** Reemplaza automáticamente instancias fallidas.
- **Plantilla de lanzamiento:** Definen AML, tipo, **Security Group**, **User Data**, etc.
 - **CLF:** En nuevos despliegues, la consola y la docu usan **Launch Template** (moderno, versionado, más flexible); **Launch Configuration** (**LEGACY**) — puede aparecer como opción «antigua» en trampas.




💡 Enunciados «¿más EC2 cuando sube CPU?» → EC2 Auto Scaling + métricas típicamente Amazon CloudWatch (se ve en otros módulos).

AUTO SCALING



- **Scaling policies (políticas de escalado):**
Target Tracking (seguimiento de objetivo)
 - Step Scaling
 - Scheduled Scaling
- **Elasticidad:** subir y bajar (**scale in / scale out**).
- Con **Elastic Load Balancing (ELB)** (balanceo de carga elástico): el **ASG** registra/elimina del **balanceador** instancias que nacen o mueren.
- Alta disponibilidad: instancias en **varias AZ**.



💡 Launch Template = enfoque moderno (versiones, flexibilidad); Launch Configuration = **LEGACY** en narrativas CLF.

💡 Desired capacity no puede estar fuera del rango [min, max] lógico de la narrativa del examen.

CHECK YOURSELF?



Un **ASG** tiene **min=2, desired=4, max=8**. ¿Puede el sistema escalar **desired** a 1?



¿Cómo se llama la acción de **agregar instancias** EC2 en un ASG ante aumento de carga? ¿Y la de **eliminarlas** cuando baja?

ANSWERS



✓ **No.** El valor desired no puede ser menor que el **mínimo** (min=2). La configuración [**min**, **desired**, **max**] debe respetar $\text{min} \leq \text{desired} \leq \text{max}$.



✓ **Scale out** (escalar hacia fuera) para agregar; **scale in** (escalar hacia dentro) para eliminar. Ambas son parte de la **elasticidad** (elasticity) del ASG.






MÓDULO M7

Sesión 7.4 — Elastic Load Balancing — ELB



¿QUÉ ES EL LOAD BALANCING?

- El Load Balancing o balanceo de carga, es el **proceso de distribuir tráfico o solicitudes** entre **múltiples servidores o recursos** para evitar que uno solo se sobrecargue.
- **Alta Disponibilidad:** Si un servidor falla, el balanceador redirige el tráfico a los servidores activos.
- **Mayor Rendimiento:** Se reducen los tiempos de respuesta para los usuarios.
- **Escalabilidad:** Permite añadir o quitar servidores según la demanda sin interrumpir el servicio.
- **Seguridad:** Algunos balanceadores pueden proteger contra ataques DDoS distribuyendo el tráfico malicioso



aws

¿QUÉ ES AWS ELASTIC LOAD BALANCING (ELB)?




- Servicio administrado de **AWS** que distribuye automáticamente el tráfico entrante entre múltiples recursos como **instancias**, **contenedores**, pods o **direcciones IP**.
- Se integra fácilmente con servicios como:
 - Amazon EC2
 - Amazon ECS
 - Amazon EKS
 - AWS Auto Scaling
- Tipos de Balanceadores de Carga en AWS:
 - **Application** Load Balancer (**ALB**)
 - **Network** Load Balancer (**NLB**)
 - **Gateway** Load Balancer (**GWLB**)
 - **Classic** Load Balancer (**CLB**).
- AWS administra la infraestructura, mantenimiento y disponibilidad del balanceador.



APPLICATION LOAD BALANCER

- Protocolos **HTTP / HTTPS / gRPC** (Capa 7).
- Funciones de **enrutamiento HTTP**.
- DNS estático (URL).



aws


NETWORK LOAD BALANCER

- Protocolos **TCP / UDP** (Capa 4)
- **Alto rendimiento:** millones de **peticiones** por **segundo**.
- **IP estática** a través de **IP elástica**.



GATEWAY LOAD BALANCER

- Es un servicio de red que facilita la implementación, el escalado y la gestión de dispositivos virtuales de seguridad de terceros, como:
 - Firewalls
 - Sistemas de detección de intrusiones
 - Análisis de paquetes)
- Protocolo **GENEVE** en paquetes IP (Capa 3)
- Enrutar el tráfico a los **firewalls** que gestionas en las instancias **EC2**.
- Detección de **intrusos**.



CLASSIC LOAD BALANCER


- Servicio de balanceo de carga original de AWS, diseñado para distribuir el tráfico entrante de aplicaciones entre múltiples **instancias EC2** en distintas zonas de disponibilidad.
- Funciona en las **capas 4** (transporte) y **7** (aplicación) del modelo OSI.
- **Producto heredado**: Aunque funcional, se considera una tecnología antigua (**LEGACY**). AWS recomienda utilizar **Application Load Balancers (ALB)** o **Network Load Balancers (NLB)** para nuevas aplicaciones, ya que ofrecen mayor flexibilidad y características avanzadas.



aws

CARACTERISTICAS

- **Load balancer (balanceador de carga):** reparte solicitudes entrantes entre **targets** (instancias en varias AZ).
- **Health checks (comprobaciones de salud):** si un **target** falla el check, el balanceador **deja de enviarle tráfico nuevo** hasta que vuelva a estar **healthy** (patrón CLF junto con **ASG** que **sustituye** instancias no saludables).
- **Sticky sessions** (afinidad de sesión) en **ALB:** enruta al mismo target la sesión HTTP; útil para apps con estado local — truco de examen al mezclar con **stateless** microservicios.



💡 «Ultra low latency, TCP puro masivo» → NLB (Network Load Balancer / balanceador de red*)

QUÉ LOAD BALANCER ELEGIR



	Tipo (EN)	Capa OSI	Puerto / protocolo típico	Idea examen
	Application Load Balancer — ALB	7	HTTP, HTTPS	Rutas por path, host, cabeceras
	Network Load Balancer — NLB	4	TCP, UDP ultra bajo retardo	Alto rendimiento (throughput alto), IP estática opcional por AZ
	Gateway Load Balancer — GWLB	3 (integración especial)	Appliances de red (FW, IDS/IPS)	Tráfico a dispositivos de seguridad virtuales
	Classic Load Balancer — CLB	LEGACY (heredado)	Mezcla antigua	NO nuevo diseño

💡 «Classic está bien para arquitectura nueva» → FALSO.

💡 Health check fallido → el balanceador deja de enviar tráfico al target afectado hasta que vuelva healthy (combinar mentalmente con ASG que puede reemplazar la instancia).



CHECK YOURSELF?



Un equipo necesita enrutar solicitudes **HTTPS** a distintos microservicios según la **ruta URL** (/api, /web, /admin). ¿**ALB** o **NLB**?



¿En qué **capa del modelo OSI** opera el **NLB**?



ANSWERS



✓ **ALB** (Application Load Balancer / balanceador de aplicación, capa 7). **NLB** opera en capa 4 (**TCP/UDP**) y no inspecciona rutas HTTP.



✓ **Capa 4** (Transport Layer / TCP/UDP). **ALB** opera en **capa 7** (Application Layer / HTTP/HTTPS).



MÓDULO M7

Sesión 7.5: Banco de práctica



PREGUNTA 1



Una tienda online experimenta un pico de tráfico durante el Black Friday y necesita **agregar automáticamente instancias EC2**. ¿Qué acción realiza el **Auto Scaling Group (ASG)**?

- A) Scale in (eliminar instancias)
- B) Scale out (agregar instancias)
- C) Vertical scaling (aumentar tipo de instancia)
- D) Snapshot de las instancias actuales



PREGUNTA 1



Una tienda online experimenta un pico de tráfico durante el Black Friday y necesita **agregar automáticamente instancias EC2**. ¿Qué acción realiza el **Auto Scaling Group (ASG)**?



Respuesta correcta: B



Scale out (escalar hacia fuera) es la acción de agregar instancias ante incremento de demanda. Scale in elimina instancias cuando la carga baja. El escalado vertical (cambiar tipo de instancia) no es la función principal de un ASG — este escala horizontalmente.



Jemjaf

PREGUNTA 2



Un **ASG** tiene **min=2**, **desired=4**, **max=8**. ¿Cuál de los siguientes valores de **desired capacity** es inválido según esta configuración?

- A) 3
- B) 6
- C) 8
- D) 1



PREGUNTA 2



Un **ASG** tiene **min=2**, **desired=4**, **max=8**. ¿Cuál de los siguientes valores de **desired capacity** es inválido según esta configuración?



Respuesta correcta: D



El valor desired debe estar en el rango [min, max]: $\text{mínimo} \leq \text{desired} \leq \text{máximo}$. Con min=2, el valor 1 viola la restricción min. El ASG nunca permitirá bajar de 2 instancias.



PREGUNTA 3



Una empresa necesita distribuir tráfico **HTTPS** y **enrutar solicitudes a diferentes microservicios** según la **ruta URL** (/usuarios, /pedidos). ¿Qué tipo de Load Balancer elegir?

- A) Network Load Balancer (NLB)
- B) Classic Load Balancer (CLB)
- C) Application Load Balancer (ALB)
- D) Gateway Load Balancer (GWLB)



PREGUNTA 3



Una empresa necesita distribuir tráfico **HTTPS** y **enrutar solicitudes a diferentes microservicios** según la **ruta URL** (/usuarios, /pedidos). *¿Qué tipo de Load Balancer elegir?*



Respuesta correcta: C



ALB (Application Load Balancer) opera en capa 7 (HTTP/HTTPS) e inspecciona el contenido de la solicitud, permitiendo enrutar por path, host, cabeceras o método HTTP. NLB opera en capa 4 (TCP/UDP) y no entiende rutas HTTP. CLB es **LEGACY**.



Jemjaf

PREGUNTA 4



¿Qué combinación de servicios es la recomendada para lograr **alta disponibilidad (HA)** y **escalado automático** en una aplicación web en AWS?

- A) EC2 instancia única con Elastic IP
- B) Elastic Load Balancer (ELB) + EC2 Auto Scaling Group (ASG) en múltiples AZ
- C) Amazon S3 + CloudFront para toda la lógica
- D) Instancia EC2 única con Reserved Instance de 3 años



PREGUNTA 4



¿Qué combinación de servicios es la recomendada para lograr **alta disponibilidad (HA)** y **escalado automático** en una aplicación web en AWS?



Respuesta correcta: B



El patrón canónico AWS para alta disponibilidad es ELB + ASG + multi-AZ: el balanceador distribuye tráfico entre AZ, el ASG mantiene el número deseado de instancias saludables y escala automáticamente. Ninguna instancia única (con o sin Reserved Instance) ofrece HA real.



Jemjaf

PREGUNTA 5



Una empresa tiene **5 Elastic IPs (EIPs)** en su cuenta. Tres están asociadas a instancias en ejecución; las otras **dos no están asociadas** a ningún recurso. *¿Cuál es la situación de costos?*

- A) Todas las EIPs son gratuitas siempre
- B) Las 3 EIPs asociadas generan costo; las 2 sin asociar son gratuitas
- C) Las 2 EIPs sin asociar generan costo; las 3 asociadas a instancias en ejecución son gratuitas
- D) Las 5 EIPs generan el mismo costo sin importar si están asociadas o no

PREGUNTA 5



Una empresa tiene **5 Elastic IPs (EIPs)** en su cuenta. Tres están asociadas a instancias en ejecución; las otras **dos no están asociadas** a ningún recurso. ¿Cuál es la situación de costos?



Respuesta correcta: C



Las EIPs sin asociar (idle) generan costo para desincentivar el acaparamiento de IPs públicas del espacio IPv4 global. Las EIPs asociadas a instancias en ejecución suelen ser gratuitas en el patrón estándar de uso. Lección práctica: libera las EIPs que no uses.



Jemjaf

PREGUNTA 6



Un arquitecto sugiere usar **Classic Load Balancer (CLB)** para una nueva aplicación.
¿Por qué esta recomendación es incorrecta?

- A) El CLB no puede distribuir tráfico HTTP
- B) El CLB requiere licencias adicionales de pago
- C) El CLB es un servicio heredado (**LEGACY**) — AWS recomienda ALB o NLB para nuevas arquitecturas
- D) El CLB solo funciona con instancias de tipo t2



PREGUNTA 6



Un arquitecto sugiere usar **Classic Load Balancer (CLB)** para una nueva aplicación.
¿Por qué esta recomendación es incorrecta?



Respuesta correcta: C



El CLB es un servicio heredado (**LEGACY**). AWS lo mantiene para retrocompatibilidad pero recomienda explícitamente ALB para HTTP/HTTPS y NLB para TCP/UDP en nuevas arquitecturas. No añade restricción de tipo de instancia ni costo especial — es simplemente tecnología obsoleta.



PREGUNTA 7



Una empresa sabe que **todos los viernes a las 18:00** su aplicación recibe el doble de tráfico. ¿Qué política de ASG es más eficiente?

- A) Target Tracking basado en CPU
- B) Scheduled Scaling (escalado programado)
- C) Scale in manual cada viernes a las 17:59
- D) Step Scaling con umbral del 80% de CPU



PREGUNTA 7



Una empresa sabe que **todos los viernes a las 18:00** su aplicación recibe el doble de tráfico. ¿Qué política de ASG es más eficiente?



Respuesta correcta: B



Scheduled Scaling (escalado programado) permite aumentar la capacidad antes del pico conocido, en lugar de esperar a que la CPU suba y el Target Tracking reaccione (con cierto retraso). Para cargas predecibles y cíclicas, el escalado programado es más eficiente y económico.



Jemjaf

PREGUNTA 8



¿Cuáles son los **DOS componentes principales** para implementar **alta disponibilidad (HA)** de una aplicación web en múltiples AZ en AWS? (Seleccione DOS.)

- A) Amazon S3 para almacenar el código de la aplicación
- B) Elastic Load Balancer (ELB) para distribuir el tráfico entre AZ
- C) Amazon RDS Multi-AZ para la base de datos del front-end
- D) EC2 Auto Scaling Group (ASG) con instancias en múltiples AZ
- E) AWS CloudTrail para auditar las acciones de los usuarios

PREGUNTA 8



¿Cuáles son los **DOS componentes principales** para implementar **alta disponibilidad (HA)** de una aplicación web en múltiples AZ en AWS? (Seleccione DOS.)



Respuesta correcta: B y D



ELB distribuye el tráfico entre instancias en múltiples AZ, evitando un punto único de falla en la capa de red. ASG mantiene el número deseado de instancias saludables en múltiples AZ y reemplaza instancias fallidas. S3 y CloudTrail son servicios de soporte, no los componentes de HA de cómputo. RDS Multi-AZ aplica a la capa de datos, no a la capa de aplicación web.



Jemjaf

PREGUNTA 9



Una instancia **EC2** detrás de un **Application Load Balancer (ALB)** comienza a **fallar los health checks**. *¿Qué ocurre con el tráfico de usuarios y la instancia?*

- A) El ALB sigue enviándole tráfico hasta que un operador reinicie la instancia manualmente
- B) El ALB deja de enviar tráfico a esa instancia no saludable; el ASG puede terminar y reemplazar la instancia según políticas de grupo
- C) CloudWatch apaga automáticamente la VPC de la instancia
- D) La Elastic IP redistribuye sola el tráfico a otra región

PREGUNTA 9



Una instancia **EC2** detrás de un **Application Load Balancer (ALB)** comienza a **fallar los health checks**. *¿Qué ocurre con el tráfico de usuarios y la instancia?*



Respuesta correcta: B



El balanceador marca el target como unhealthy y deja de dirigir tráfico nuevo a esa instancia mientras siga fallando. En arquitecturas típicas con ASG registrado en el target group, el ASG puede reemplazar la instancia según políticas (unhealthy replacement). CloudWatch no «apaga VPC»; Elastic IP no redistribuye tráfico mágicamente entre instancias.



Jemjaf



MÓDULO M7

Sesión 7.5: Datos de certificación



DATOS DE CERTIFICACIÓN



Tema	Dato EN / ES corto
ASG / Auto Scaling	Ajusta count instancia ante demanda (min/desired/max)
ALB / balanceador de aplicación	Layer 7 / capa 7, HTTP/HTTPS, routing contenido
NLB / balanceador de red	Layer 4, TCP/UDP, baja latencia
CLB / Classic Load Balancer	legacy — evitar nuevo
EIP / Elastic IP / IP estática	IPv4 estático; cuidado con idle (ociosa) incurring cost
Launch Template vs Launch Configuration	Template = moderno, versionado; Configuration = legacy
ALB health checks	Target unhealthy → sin tráfico nuevo; ASG puede reemplazar
Sticky sessions (ALB)	Afinidad de sesión HTTP; distractor si el enunciado pide stateless
Integración típica	ELB + ASG + multi-AZ para HA patrones CLF



Jemjaf

TRAMPAS FRECUENTES

- Elegir **NLB** para routing por Path **HTTP (ALB)**.
- Olvidar que **Classic** está en retirada conceptual.
- Creer que **Elastic IP** «*gratis*» siempre ignorando **unattached** (no asociada).
- «*Escala predecible / horaria (Black Friday 18:00)*» → **Scheduled Scaling** (no Target Tracking reactivo solo).
- «*Sube CPU — mantén un umbral fijo (p. ej. 50 %)*» → **Target Tracking**.
- «*Escalón al cruzar umbrales (step)*» → **Step Scaling**.
- Una sola instancia **EC2** con **Reserved Instance** de 3 años ≠ alta disponibilidad (sigue siendo punto único de fallo).
- Confundir **health checks** del **ELB** (dejar de enviar tráfico) con **CloudWatch** (métricas) sin leer el enunciado.

